



المملكة المغربية  
المندوبية السامية للتخطيط  
ⵜⴰⴳⴷⴰⵢⵜ ⵜⴰⵎⴻⵔⴰⵏⵜ ⵏ ⵜⴰⵖⴻⵔⴰ ⵏ ⵍⵎⴰⵔ  
HAUT-COMMISSARIAT AU PLAN

# Rapport de projet Séries Chronologiques

*Réalisé par:*

Safaa Nidabdellah &  
Hafsa Ezzidani



# Table de matières



<b>1</b>	<b>Introduction</b>	<b>3</b>
1.1	Description des données	3
1.2	Chargement des données	3
1.3	Division des données	3
<b>2</b>	<b>Illustration graphique</b>	<b>4</b>
2.1	Illustration graphique	4
2.2	Analyse Qualitative	4
<b>3</b>	<b>Test de stationnarité</b>	<b>5</b>
3.1	Autocorrélogramme	5
3.2	Tests de stationnarité	5
3.2.1	Dickey-Fuller augmenté	5
3.2.2	KPSS	6
3.2.3	Conclusion	6
<b>4</b>	<b>Stationnarisation de la série</b>	<b>7</b>
4.1	Première différenciation	7
4.2	Différenciation saisonnière	7
<b>5</b>	<b>Méthode de Box-Jenkins</b>	<b>9</b>
5.1	Identification du modèle	9
5.1.1	Autocorrélogramme	9
5.1.2	Autocorrélogramme partiel	10
5.2	Estimation	11
5.3	Validation	11
5.3.1	Test de Box-Pierce	11
5.3.2	Critère de l'AIC	12
5.3.3	Interprétation	12
5.4	Prévision	13
<b>6</b>	<b>Évaluation des prévisions</b>	<b>14</b>
<b>7</b>	<b>Vérification de la normalité</b>	<b>14</b>
<b>8</b>	<b>Conclusion</b>	<b>15</b>

# 1 Introduction

## 1.1 Description des données

---

La série étudiée représente la production mensuelle moyenne de lait par vache aux États-Unis, exprimée en kilogrammes, et couvre intégralement la période allant de janvier 1962 à décembre 1975, soit 168 observations mensuelles consécutives.

## 1.2 Chargement des données

---

On importe le fichier csv sur R

	Month Milk Production
1962-01-01	589
1962-02-01	561
1962-03-01	640
⋮	⋮
1975-10-01	827
1975-11-01	797
1975-12-01	843

## 1.3 Division des données

---


Pour modéliser et valider les prévisions, le jeu de données a été scindé : les 156 premières observations (janvier 1962 – décembre 1974), soit environ 90 % de la série, constituent le jeu d'apprentissage utilisé pour estimer les paramètres du modèle. Les 12 observations restantes (janvier – décembre 1975), représentant les 10 % les plus récents, forment le jeu test dédié à l'évaluation hors-échantillon.

## 2 Illustration graphique

### 2.1 Illustration graphique

---

**Production Mensuelle de Lait**



### 2.2 Analyse Qualitative

---


- \* **Tendance:** La série présente une tendance haussière soutenue
- \* **Saisonnalité:** Chaque année : creux prononcé en hiver (déc.-févr.), pic net en été (juin-août).

## 3 Test de stationnarité

Dans ce qui suit, on effectue les tests et les calculs sur l'échantillon d'apprentissage

### 3.1 Autocorrélogramme

---



La fonction d'autocorrélation ne s'éteint pas rapidement, alors la série n'est pas stationnaire.

Pour valider cela on effectue les tests de stationnarité: Dickey-Fuller augmenté et KPSS.

### 3.2 Tests de stationnarité

---

#### 3.2.1 Dickey-Fuller augmenté

```
Augmented Dickey-Fuller Test
data:  train_ts
Dickey-Fuller = -9.9714, Lag order = 5, p-value = 0.01
```

La p-value est inférieur à 0.05 ainsi  $H_0$  est rejetée donc d'après le test d'ADF , la série est stationnaire

### 3.2.2 KPSS

```
KPSS Test for Level Stationarity
data:  train_ts
KPSS Level = 2.7659, Truncation lag parameter = 4, p-value =
0.01
```

La p-value est inférieure à 0.05 ainsi  $H_0$  est rejetée donc d'après le test de KPSS, la série est non stationnaire

### 3.2.3 Conclusion


Les tests ne sont pas unanimes sur le résultat de la stationanrité. La série n'est donc pas stationnaire. On procède à la stationnariser par différenciation.

## 4 Stationnarisation de la série

### 4.1 Première différenciation

---

**Autocorrélogramme après première différenciation**



Une première différenciation a été appliquée pour supprimer la tendance. Toutefois, la présence persistante de motifs saisonniers visibles dans l'ACF impose une différenciation saisonnière supplémentaire.

## 4.2 Différenciation saisonnière

---

Après différenciation saisonnière la série devrait être stationnaire. Pour s'en assurer, on effectue les tests de stationnarité.

### Augmented Dickey-Fuller Test

```
data: train_dif1s
Dickey-Fuller = -5.8483, Lag order = 5, p-value = 0.01
alternative hypothesis: stationary
```

### KPSS Test for Level Stationarity

```
data: train_dif1s
KPSS Level = 0.040142, Truncation lag parameter = 4, p-value
= 0.1
```

### Phillips-Perron Unit Root Test

```
data: train_dif1s
Dickey-Fuller Z(alpha) = -189.4, Truncation lag parameter =
4, p-value = 0.01
alternative hypothesis: stationary
```

Tous les tests montrent que la série est stationnaire.  
Alors on procède à la méthode de Box-Jenkins.



# 5 Méthode de Box-Jenkins


## 5.1 Identification du modèle

---

$$SARIMA(p, 1, q)(P, 1, Q)_{12}$$

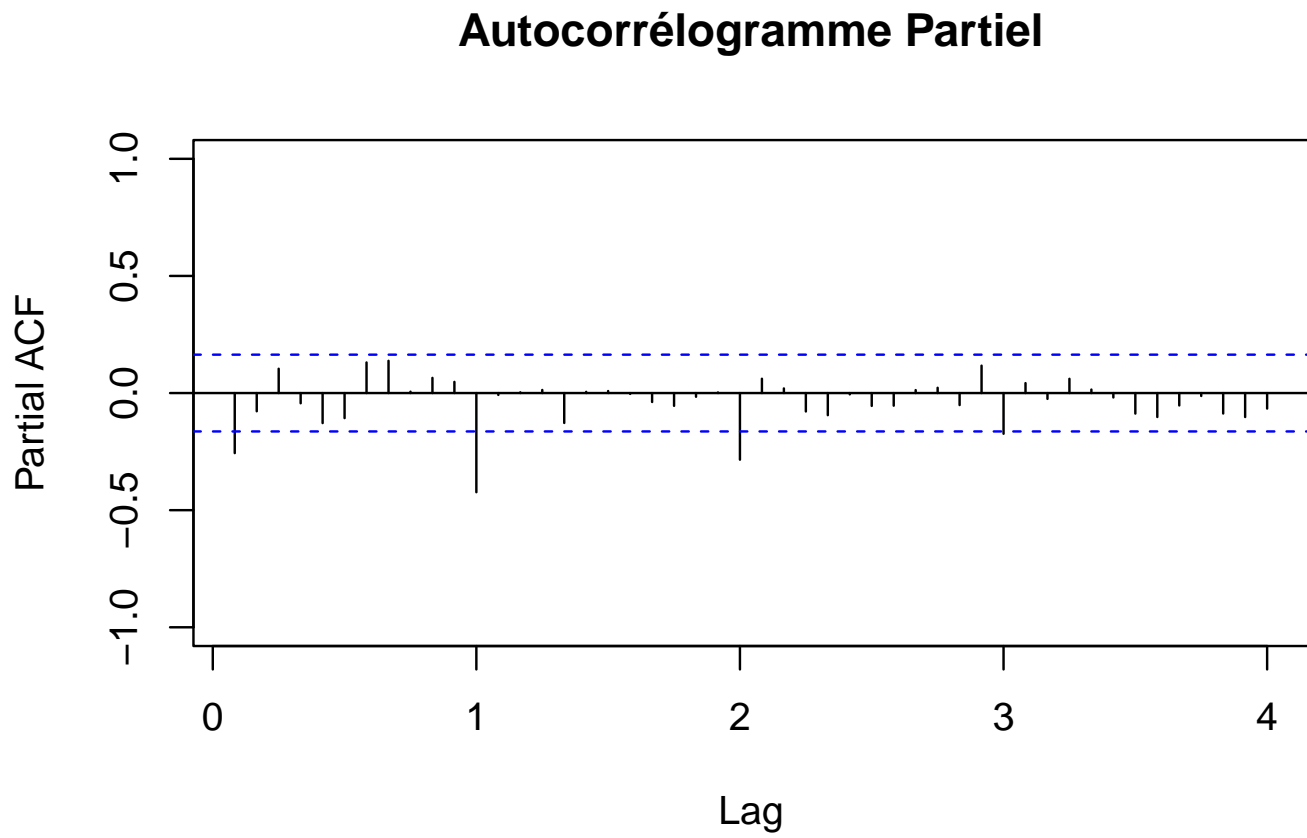
### 5.1.1 Autocorrélogramme

**Autocorrélogramme**



Alors:  $q_{max} = 2$  et  $Q_{max} = 1$

### 5.1.2 Autocorrélogramme partiel



Alors:  $p_{max} = 1$  et  $P_{max} = 2$

## 5.2 Estimation

---

Pour l'estimation, nous avons procédé à une recherche systématique des spécifications SARIMA possibles :

- \* Ordres réguliers :  $p \in \{0, 1\}$  et  $q \in \{0, 1, 2\}$
- \* Ordres saisonniers :  $P \in \{0, 1, 2\}$  et  $Q \in \{0, 1\}$
- \* Différenciations fixées :  $d = 1$  (tendance) et  $D = 1$  (saisonnalité), période  $s = 12$

Nous n'avons conservé qu'une spécification lorsqu'aucun de ses coefficients (hors variance) n'était non-significatif : critère  $|z| > 1,96$  (niveau 5 %)

Cette procédure aboutit à 13 modèles plausibles, tous compatibles avec la structure  $(p, 1, q)(P, 1, Q)_{12}$ . On obtient notamment :

*SARIMA*(0, 1, 0)(0, 1, 1)<sub>12</sub>  
*SARIMA*(0, 1, 0)(1, 1, 0)<sub>12</sub>  
*SARIMA*(0, 1, 0)(2, 1, 0)<sub>12</sub>  
*SARIMA*(0, 1, 1)(0, 1, 0)<sub>12</sub>  
*SARIMA*(0, 1, 1)(0, 1, 1)<sub>12</sub>  
*SARIMA*(0, 1, 1)(1, 1, 0)<sub>12</sub>  
*SARIMA*(0, 1, 1)(2, 1, 0)<sub>12</sub>  
*SARIMA*(1, 1, 0)(0, 1, 0)<sub>12</sub>  
*SARIMA*(1, 1, 0)(0, 1, 1)<sub>12</sub>  
*SARIMA*(1, 1, 0)(1, 1, 0)<sub>12</sub>  
*SARIMA*(1, 1, 0)(2, 1, 0)<sub>12</sub>  
*SARIMA*(1, 1, 2)(0, 1, 0)<sub>12</sub>  
*SARIMA*(1, 1, 2)(0, 1, 1)<sub>12</sub>

## 5.3 Validation

---

### 5.3.1 Test de Box-Pierce

Après l'estimation, chacun des 13 modèles jugés “significatifs” a été soumis au test de Box–Pierce.

Seuil :  $p\text{-value} > 0,05 \rightarrow$  absence d'autocorrélation résiduelle, modèle accepté.

7 modèles sur 13 présentent des résidus assimilables à un bruit blanc ( $p > 0,05$ ). Les six autres sont rejetés pour autocorrélation résiduelle significative.

$SARIMA(0, 1, 1)(0, 1, 1)_{12}$   
 $SARIMA(0, 1, 1)(1, 1, 0)_{12}$   
 $SARIMA(0, 1, 1)(2, 1, 0)_{12}$   
 $SARIMA(1, 1, 0)(0, 1, 1)_{12}$   
 $SARIMA(1, 1, 0)(1, 1, 0)_{12}$   
 $SARIMA(1, 1, 0)(2, 1, 0)_{12}$   
 $SARIMA(1, 1, 2)(0, 1, 1)_{12}$

### 5.3.2 Critère de l'AIC

Les sept modèles qui avaient passé le test de Box-Pierce ont été comparées au moyen de l'Akaike Information Criterion (AIC)

Modèle	p-value(BP)	AIC
$SARIMA(0, 1, 1)(0, 1, 1)_{12}$	0.5330	988.2
$SARIMA(1, 1, 0)(0, 1, 1)_{12}$	0.4617	988.5
$SARIMA(1, 1, 2)(0, 1, 1)_{12}$	0.5007	989.1
$SARIMA(0, 1, 1)(2, 1, 0)_{12}$	0.3180	994.9
$SARIMA(1, 1, 0)(2, 1, 0)_{12}$	0.2674	995.1
$SARIMA(1, 1, 0)(1, 1, 0)_{12}$	0.2107	1003.1
$SARIMA(0, 1, 1)(1, 1, 0)_{12}$	0.2509	1003.3

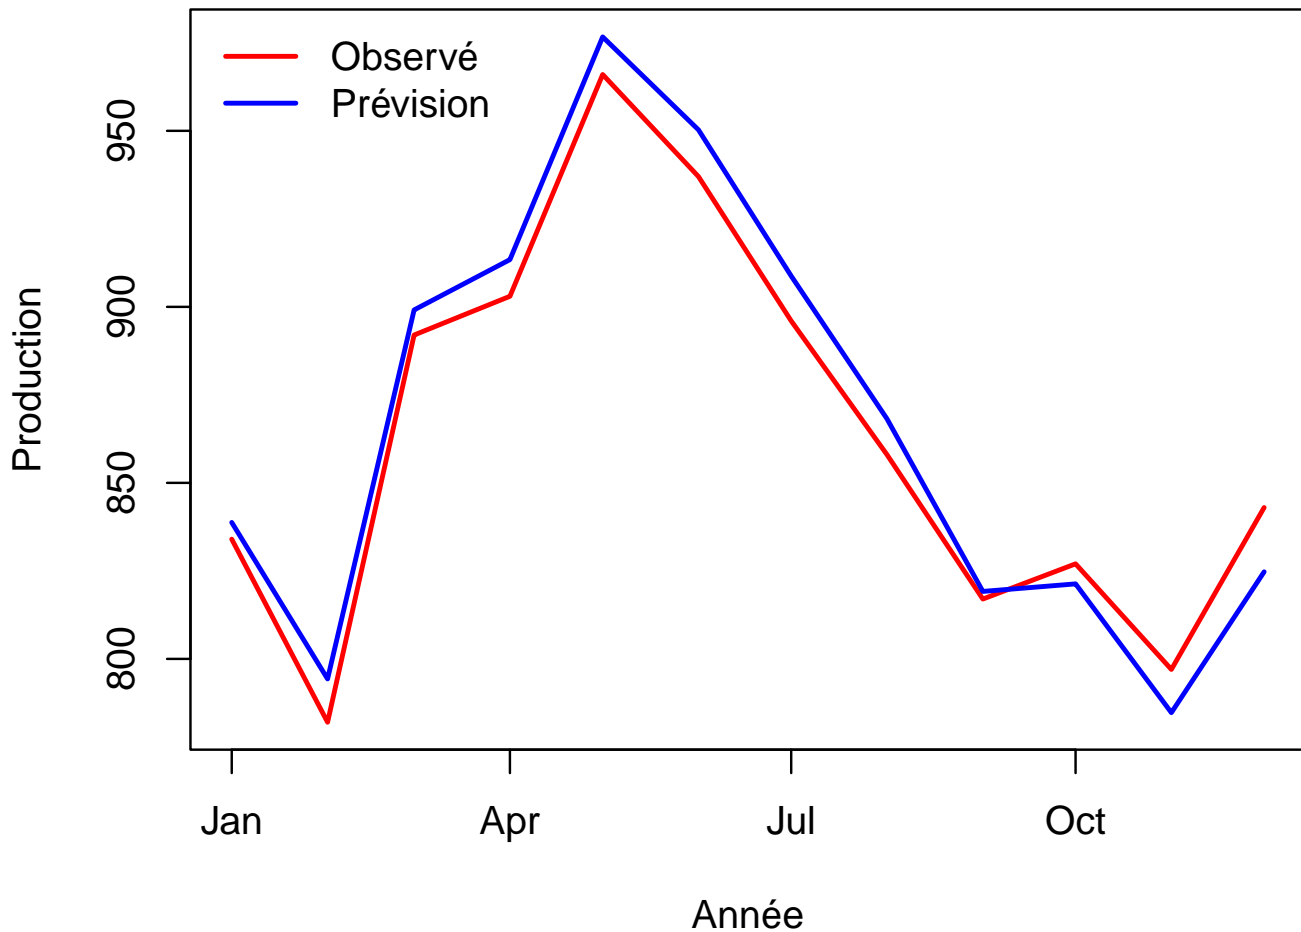
### 5.3.3 Interprétation

Le modèle  $SARIMA(0, 1, 1)(0, 1, 1)_{12}$  possède l'AIC le plus faible; il est donc retenu comme modèle final.

## 5.4 Prédiction

Pour évaluer la capacité prédictive du modèle sélectionné  $SARIMA(0, 1, 1)(0, 1, 1)_{12}$ , nous avons généré une pré à 12 mois (janvier – décembre 1975) et nous l'avons comparée à l'échantillon de validation.

**Prédiction des 12 derniers mois  
SARIMA (0,1,1)(0,1,1)[12]**



## 6 Évaluation des prévisions

Les performances du modèle final  $SARIMA(0, 1, 1)(0, 1, 1)_{12}$  ont été quantifiées à l'aide de deux indicateurs classiques :

- **RMSE** (Root Mean Square Error): 10,85 kg
- **MAPE** (Mean Absolute Percentage Error): 1.15%

La production mensuelle se situe en moyenne autour de 750 kg par vache ; une erreur quadratique moyenne de 10,9 kg représente donc 1,4 % du niveau moyen.

Le MAPE confirme ce diagnostic : à 1,16 %, l'erreur absolue relative est quasi négligeable.

## 7 Vérification de la normalité

On effectue le test de Shapiro-Wilk sur les résidus du modèle

```
Shapiro-Wilk normality test
data:  std_residuals
W = 0.96115, p-value = 0.0002294
```

$p = 0,00023 < 0,05$  on rejette l'hypothèse nulle de normalité.

## 8 Conclusion

L'analyse de la production mensuelle de lait par vache (1962-1975) a montré une tendance haussière soutenue et une saisonnalité annuelle marquée. Après une double différenciation  $(1-B)(1-B^{12})$ , la série est devenue stationnaire, ce qui a permis d'identifier puis d'estimer un ensemble de modèles SARIMA. Le filtrage successif par :

1. significativité des coefficients,
2. test de Box-Pierce (résidus indépendants)
3. critère d'information d'Akaike,

a conduit à retenir le modèle  $SARIMA(0, 1, 1)(0, 1, 1)_{12}$ . Sur l'année de validation (1975), ce modèle atteint :

- RMSE = 10,85 kg (1,4 % du niveau moyen)
- MAPE = 1,16 %

ce qui représente une performance largement meilleure qu'un simple modèle naïf basé sur la saison précédente. Bien que le test de Shapiro-Wilk rejette la normalité ( $p = 0,0002$ ), les écarts observés aux extrêmes restent mineurs et n'altèrent pas la pertinence des prévisions ponctuelles.

En pratique, le modèle fournit donc des prévisions mensuelles fiables